

LAPORAN MINI - PROJECT
CSCE604133 Computer Vision

**Rekonstruksi Citra Menggunakan Pendekatan RePaint
(*Diffusion-Based Inpainting*) pada *Dataset* Emoji**

CVitamin

2206081736

Hilmy Ammar Darmawan

2206081894

Wahyu Hidayat

2206081950

Ariana Nurlayla Syabandini

2306226864

Irma Nia Alwijah

Semester Ganjil 2025/2026

Fakultas Ilmu Komputer

Universitas Indonesia

Daftar Isi

Daftar Isi	2
1. Pendahuluan	3
1.1. Latar Belakang	3
1.2. Pertanyaan Penelitian	4
1.3. Tujuan Penelitian	4
1.4. Batasan Penelitian	5
2. Studi Literatur	6
2.1. Image Inpainting	6
2.2. Denoising Diffusion Probabilistic Models (DDPM)	6
2.3. RePaint: Inpainting using Denoising Diffusion Probabilistic Models	7
2.4. Metrik Evaluasi	8
3. Metodologi	10
3.1. Deskripsi Dataset	10
3.2. Desain Eksperimen	11
3.2.1. Persiapan Environment dan Data	11
3.2.2. Arsitektur Model dan Scheduler	11
3.2.3. Training Loop	11
3.2.4. Evaluasi OTI (dengan Ground Truth)	12
3.2.5. Generasi HTI (tanpa Ground Truth)	12
3.2.6. Variabel Kunci untuk Analisis	13
4. Hasil dan Analisis	15
4.1. Hasil Eksperimen	15
4.2. Diskusi	16
5. Penutup	18
5.1. Kesimpulan	18
5.2. Saran (Future work)	18
5.3. Refleksi Kelompok	18
Daftar Referensi	19

1. Pendahuluan

1.1. Latar Belakang

Computer vision merupakan disiplin ilmu yang berupaya mereplikasi kemampuan persepsi visual manusia melalui algoritma komputasi. Salah satu permasalahan klasik sekaligus fundamental dalam bidang ini adalah *image inpainting*, yaitu proses merekonstruksi bagian yang hilang atau rusak dari suatu citra sedemikian rupa sehingga hasil akhirnya tampak utuh dan realistis bagi pengamat manusia. Relevansi masalah ini meluas dari restorasi arsip foto kuno, penghapusan objek yang tidak diinginkan dalam fotografi digital, hingga perbaikan transmisi video yang mengalami *packet loss*.

Solusi untuk masalah ini didominasi oleh pendekatan berbasis difusi (*diffusion-based*) atau pencocokan potongan (*patch-match*). Metode-metode ini bekerja dengan asumsi bahwa informasi yang hilang dapat diisi dengan menyalin tekstur dari area sekitarnya yang valid. Meskipun efektif untuk latar belakang bertekstur stasioner, seperti rumput atau langit, metode ini gagal total ketika kerusakan terjadi pada struktur semantik yang unik, seperti wajah manusia atau objek geometris spesifik. Dalam konteks dataset emoji yang digunakan pada proyek ini, tantangannya menjadi unik karena citra emoji memiliki warna solid (*flat regions*) dan batas tegas (*sharp edges*) yang membentuk ekspresi emosional. Metode tradisional cenderung menghasilkan efek buram (*blur*) yang merusak makna ekspresi tersebut.

Dalam sepuluh tahun terakhir, pendekatan berbasis Deep Learning mulai menggantikan pendekatan tradisional. *Generative Adversarial Networks* (GANs) sempat menjadi standar emas karena kemampuannya menghasilkan tekstur yang tajam. Namun, GANs dikenal sulit untuk dilatih (*training instability*) dan rentan terhadap *mode collapse*, di mana model gagal menangkap keseluruhan variasi distribusi data. Baru-baru ini, *Denoising Diffusion Probabilistic Models* (DDPM) muncul sebagai kelas baru model generatif yang menawarkan stabilitas pelatihan yang lebih baik dan kualitas sampel yang superior, meskipun dengan biaya komputasi inferensi yang lebih tinggi.

Proyek akhir ini menugaskan kami untuk mengimplementasikan dan mengevaluasi pendekatan rekonstruksi citra pada *dataset* emoji yang *corrupted*. Berdasarkan studi literatur dan ketersediaan metode *state-of-the-art*, kelompok kami memilih metode RePaint (Lugmayr et al., 2022). Metode ini unik karena memanfaatkan model difusi yang telah dilatih (*pre-trained*) dan memodifikasi proses *sampling*-nya untuk melakukan *inpainting*, tanpa memerlukan pelatihan ulang (*retrain*) *neural network* khusus untuk setiap bentuk *mask*. Hal ini sangat

relevan dengan batasan proyek yang menekankan pada implementasi dan evaluasi metode yang ada.

1.2. Pertanyaan Penelitian

Berdasarkan latar belakang masalah yang telah diuraikan, tantangan utama project ini adalah melakukan restorasi citra triplet (original dalam folder orig, rusak dalam folder erased, mask dalam folder masks). Oleh karena itu, penelitian ini difokuskan untuk menjawab pertanyaan-pertanyaan spesifik yang dapat dieksplorasi melalui manipulasi kode program dan eksperimen komputasi. Berikut ini beberapa pertanyaan guna mengevaluasi kapabilitas metode yang digunakan.

1. Sejauh mana metode RePaint mampu memulihkan struktur geometris vital, seperti mata atau mulut pada emoji yang hilang akibat kerusakan atau *mask*, hanya dengan mengandalkan konteks global yang tersisa?
2. Bagaimana pengaruh jumlah langkah *resampling* dalam algoritma RePaint terhadap harmonisasi batas antara area asli (*known pixels*) dan area hasil generasi (*inpainted pixels*)? Apakah peningkatan iterasi selalu berbanding lurus dengan peningkatan kualitas visual?
3. Berapa besar biaya komputasi atau waktu inferensi yang diperlukan untuk mencapai tingkat kualitas *perceptual* tertentu, dan apakah metode ini layak digunakan dalam skenario demonstrasi *on-the-spot*, seperti yang disyaratkan untuk *Hidden Test Images* (HTI)?

1.3. Tujuan Penelitian

Penelitian ini bertujuan untuk mengevaluasi efektivitas metode RePaint dalam merestorasi informasi visual yang hilang pada citra digital, khususnya pada dataset emoji dengan struktur data triplet. Fokus utama studi mencakup pengukuran kualitas rekonstruksi terhadap berbagai variasi topologi kerusakan, yang secara spesifik dijabarkan sebagai berikut.

1. Mengoperasikan kode metode RePaint pada lingkungan komputasi (Google Colab/Kaggle) untuk memproses dataset emoji sesuai spesifikasi deliverables.
2. Mengukur kinerja metode menggunakan metrik kuantitatif standar (PSNR dan SSIM) pada Open Test Images (OTI) dan menganalisis hasilnya terhadap Ground Truth.
3. Menganalisis ketahanan model terhadap variasi topologi kerusakan (goresan *erased* vs. blok *mask* besar) yang disimulasikan melalui masker biner.

4. Menyiapkan *pipeline* inferensi yang mampu menangani *Hidden Test Images* (HTI) pada saat demonstrasi *mini project*.

1.4. Batasan Penelitian

Ruang lingkup pembahasan dibatasi pada aspek-aspek berikut agar penelitian ini tetap terarah dan dapat diselesaikan sesuai dengan tenggat waktu yang telah ditetapkan.

1. Eksperimen hanya dilakukan pada dataset emoji yang telah disediakan oleh tim asisten dosen. Tidak ada data eksternal yang digunakan untuk *training*.
2. Fokus utama adalah pada inferensi menggunakan metode RePaint. Pelatihan model difusi dari awal (*scratch*) mungkin dilakukan jika *pre-trained* model tidak tersedia atau tidak cocok, tetapi fokus analisis tetap pada mekanisme *inpainting*-nya.
3. Kode dijalankan dan dievaluasi pada lingkungan Google Colab atau Kaggle dengan kapasitas GPU gratis yang terbatas sehingga optimasi kecepatan dibatasi oleh *hardware* tersebut.
4. Penelitian ini berfokus pada pemulihan citra dengan *binary mask* yang diketahui (*non-blind inpainting*). Kasus di mana lokasi kerusakan tidak diketahui berada di luar cakupan.

2. Studi Literatur

2.1. Image Inpainting

Image Inpainting adalah sebuah teknik dalam *computer vision* yang bertujuan untuk merekonstruksi atau memulihkan bagian yang hilang, rusak, atau sengaja dihapus dari sebuah citra digital. Tujuan utama dari proses ini adalah untuk mengisi area yang kosong dengan informasi visual yang masuk akal secara semantik dan konsisten secara visual, sehingga hasil akhirnya terlihat alami dan tidak dapat dibedakan dari citra aslinya oleh manusia [1].

Metode inpainting secara umum dikategorikan menjadi dua pendekatan utama:

1. Pendekatan Tradisional: Pendekatan tradisional dalam inpainting, atau sering disebut metode berbasis *patch*, bekerja dengan prinsip menyalin informasi tekstur dari area gambar yang utuh ke bagian yang hilang. Algoritma klasik seperti *PatchMatch* mencari pola yang mirip di sekitar area target untuk mengisi kekosongan tersebut, yang sangat efektif untuk latar belakang dengan pola berulang seperti rumput atau tembok. Namun, metode ini memiliki keterbatasan karena tidak memahami konteks semantik, sehingga sering gagal merekonstruksi struktur objek yang kompleks atau unik yang tidak memiliki referensi di bagian lain gambar. [2]
2. Pendekatan *Deep Learning*: Pendekatan berbasis *Deep Learning* menggunakan jaringan saraf tiruan untuk mempelajari representasi fitur tingkat tinggi dari sekumpulan data gambar yang sangat besar. Metode ini tidak sekadar menyalin tekstur, melainkan mempelajari konteks visual untuk memprediksi isi bagian yang hilang secara semantik. Hal ini memungkinkan model untuk menghasilkan struktur baru yang koheren dan alami, seperti melengkapi bagian wajah yang hilang, meskipun informasi tersebut tidak tersedia di area sekitarnya. [3]

2.2. Denoising Diffusion Probabilistic Models (DDPM)

Denoising Diffusion Probabilistic Models (DDPM) adalah kelas model variabel laten generatif yang terinspirasi dari prinsip termodinamika non-ekuilibrium. Model ini bekerja dengan melatih *Markov chain* (rantai Markov) menggunakan *variational inference* untuk menghasilkan sampel yang cocok dengan data asli setelah waktu yang terbatas.

Secara konseptual, DDPM terdiri dari dua proses utama:

1. *Forward Process*: Rantai Markov secara bertahap menambahkan *Gaussian Noise* ke dalam data pada setiap langkah waktu sesuai dengan jadwal variansi yang telah ditentukan. Proses ini berlangsung hingga sinyal data asli hancur sepenuhnya dan berubah menjadi *noise* acak. Karena *noise* yang ditambahkan kecil, proses transisi ini cukup sederhana untuk didefinisikan secara matematis.
2. *Reverse Process*: Proses generatif yang dipelajari oleh model. Tujuannya adalah membalikkan *Forward Process* dengan menghilangkan *noise* langkah demi langkah untuk merekonstruksi gambar asli dari *noise* acak. Proses ini dimodelkan sebagai transisi *Gaussian* yang parameternya dipelajari oleh *neural network*.

Merujuk pada penelitian Ho et al. (2020), ditemukan bahwa kualitas sampel terbaik diperoleh melalui pendekatan parameterisasi khusus yang menghubungkan DDPM dengan *denoising score matching* selama pelatihan. Alih-alih mengoptimalkan batas variasi standar yang rumit, model dilatih menggunakan fungsi objektif yang disederhanakan, yang fokus pada memprediksi *noise* yang ditambahkan pada data.

Dari segi performa, metode ini terbukti mampu menghasilkan sintesis gambar berkualitas tinggi. Pada eksperimen menggunakan dataset CIFAR10 yang *unconditional*, model ini mencapai skor FID 3.17, yang mengungguli banyak model generatif canggih lainnya di literatur. Selain itu, proses *sampling* pada model ini menunjukkan karakteristik *progressive decoding*, di mana fitur skala besar (seperti bentuk global) muncul terlebih dahulu, diikuti oleh detail-detail halus pada langkah-langkah akhir proses. [4]

2.3. RePaint: Inpainting using Denoising Diffusion Probabilistic Models

Dalam penyelesaian masalah *image reconstruction*, metode yang diimplementasikan dalam penelitian ini mengacu pada pendekatan *RePaint*. *RePaint* adalah sebuah metode *inpainting* yang dibangun di atas arsitektur *Denoising Diffusion Probabilistic Models* (DDPM) yang telah dilatih sebelumnya (*pretrained*). Berbeda dengan pendekatan *Deep Learning* lain seperti GAN atau *Autoregressive* yang seringkali memerlukan pelatihan khusus untuk pola *masking* tertentu, *RePaint* memanfaatkan kemampuan generatif dari DDPM tanpa perlu melatih ulang model untuk tugas *inpainting* itu sendiri.

Prinsip kerja utama dari *RePaint* adalah memodifikasi proses *reverse diffusion* pada DDPM. Pada setiap tahapan *denoising*, model mengkondisikan proses generasi gambar berdasarkan area yang diketahui dari input. Secara teknis, area gambar yang tidak tertutup *masking* diambil langsung dari informasi gambar

input, sementara area yang hilang (*masked regions*) diprediksi dan diisi oleh model. Hal ini memastikan bahwa tekstur yang dihasilkan konsisten dengan bagian gambar yang asli.

Namun, sekadar menggabungkan area yang diketahui dan tidak diketahui sering kali menghasilkan ketidakselarasan secara semantik. Untuk mengatasi hal ini, *RePaint* memperkenalkan strategi *resampling*. Strategi ini bekerja dengan cara memajukan dan memundurkan langkah difusi selama proses inferensi. Dengan melakukan *resampling*, model memiliki kesempatan lebih besar untuk menyelaraskan informasi antara area yang di-*generate* dengan area asli, sehingga menghasilkan gambar rekonstruksi yang lebih realistis dan bermakna secara semantik. Pendekatan ini memungkinkan sistem untuk menangani berbagai bentuk kerusakan gambar, mulai dari goresan tipis hingga area hilang yang ekstrem, menggunakan model yang sama. [5]

2.4. Metrik Evaluasi

Untuk mengukur kualitas hasil rekonstruksi citra secara objektif, penelitian ini menggunakan tiga metrik standar yang mengevaluasi aspek akurasi piksel, kemiripan struktur, dan persepsi visual manusia.

1. Peak Signal-to-Noise Ratio (PSNR): [6]

Peak Signal-to-Noise Ratio (PSNR) adalah metrik evaluasi objektif yang mengukur kualitas citra rekonstruksi terhadap citra referensi (\$f\$) dengan menghitung perbandingan logaritmik antara kuadrat nilai sinyal maksimum (biasanya 255 untuk citra 8-bit) terhadap *Mean Squared Error* (MSE). Karena nilai PSNR berbanding terbalik dengan MSE, nilai PSNR yang semakin tinggi mengindikasikan tingkat kesalahan yang lebih rendah dan kualitas rekonstruksi yang semakin baik mendekati citra asli. Dalam studi komparatifnya, Horé dan Ziou (2010) menemukan bahwa PSNR memiliki sensitivitas paling tinggi terhadap degradasi berupa *additive Gaussian noise* dibandingkan jenis gangguan lainnya, menjadikannya standar yang kuat untuk mengevaluasi tugas *denoising*.

2. Structural Similarity Index (SSIM): [6]

Berbeda dengan PSNR yang berbasis pada selisih intensitas piksel semata, Structural Similarity Index (SSIM) adalah metrik yang dirancang untuk mengukur kemiripan struktural yang berkorelasi lebih baik dengan persepsi sistem visual manusia (*Human Visual System*). SSIM mengevaluasi kualitas citra dengan memodelkan distorsi ke dalam tiga

komponen independen yaitu *luminance distortion*, *loss of correlation*, and *contrast distortion* menghasilkan nilai antara 0 hingga 1 di mana nilai 1 menunjukkan identitas sempurna. Berdasarkan analisis sensitivitas, SSIM terbukti lebih efektif dan sensitif dibandingkan PSNR dalam mendeteksi degradasi yang merusak struktur visual objek, seperti yang terjadi pada kompresi JPEG.

3. Learned Perceptual Image Patch Similarity (LPIPS) [7]

LPIPS adalah metrik yang mengukur jarak perseptual antara dua citra dengan cara membandingkan aktivasi fitur dalam yang diekstraksi menggunakan jaringan saraf tiruan terlatih, seperti VGG atau AlexNet. Sebagaimana dijelaskan dalam penelitian RePaint, LPIPS menjadi standar penting dalam tugas *inpainting* karena mampu menilai kemiripan semantik tingkat tinggi. Nilai LPIPS yang rendah mengindikasikan bahwa hasil rekonstruksi terlihat nyata dan mirip secara perseptual dengan aslinya, meskipun mungkin memiliki perbedaan kecil pada level piksel yang tidak tertangkap oleh PSNR.

3. Metodologi

3.1. Deskripsi Dataset

Dataset yang digunakan berformat triplet untuk tugas *inpainting* emoji, di mana setiap sampel terdiri dari tiga komponen, gambar rusak (*erased*), gambar asli target (*orig*), dan *mask* biner (*mask*) yang menandai area hilang. Struktur file diorganisasi melalui berkas indeks bernama `index.csv` pada masing-masing folder dataset; CSV memuat kolom jalur relatif untuk *erased*, *orig*, dan *mask* sehingga pemuatan data dapat dilakukan terstandar.

- **Konten:** Citra emoji berwarna solid dengan batas tegas; setiap baris pada `index.csv` menunjuk ke pasangan file *erased*, *orig*, dan *mask* yang sesuai.
- **Mask:** Citra *grayscale* yang dibinarisasi, nilai 1 menandai “lubang” yang harus diisi. Mask di-*resize* menggunakan interpolasi *nearest* untuk menjaga ketepatan tepi.
- **Resolusi:** Semua gambar diubah ukurannya menjadi 256x256 piksel. Gambar RGB dinormalisasikan ke rentang $[-1, 1]$ (*mean* 0.5, *std* 0.5 per *channel*).
- **Split:**
 - *Train:* folder “`triplets_out`” dengan ukuran sekitar **3440** sampel.
 - Validasi OTI (*Open Test Images*): folder “`triplets_val_OTI`” dengan **20** sampel yang memiliki *ground truth* (*orig*) untuk evaluasi metrik.
 - HTI (*Hidden Test Images*): folder “`triplets_HTI`” berisi gambar *erased* dan *mask* tanpa *ground truth*, digunakan untuk generasi saja dan pengukuran waktu inferensi.
- **Mekanisme data loading:** Kelas `EmojiInpaintingDataset` membaca `index.csv`, memuat *erased* (RGB), *orig* (RGB), *mask* (L), melakukan *resize*, normalisasi, dan mengembalikan *tuple* (*erased_img*, *orig_img*, *mask_tensor*, *filename*) untuk tiap sampel.

Dengan struktur ini, kami bisa mengevaluasi rekonstruksi secara menyeluruh, menilai kualitas visual dan ketajaman tepi pada OTI lewat PSNR, SSIM, dan LPIPS, serta menguji ketahanan dan efisiensi waktu pada HTI yang mensimulasikan skenario tanpa *ground truth*. Format triplet membantu RePaint memanfaatkan konteks dari *erased* dan *mask* untuk menghasilkan isi yang masuk akal secara semantik dibandingkan target *orig*.

3.2. Desain Eksperimen

Eksperimen dirancang untuk mengevaluasi kemampuan *RePaint* (berbasis DDPM) melakukan *inpainting* pada citra emoji dengan *mask* biner. Alur kerja dibagi ke empat tahap, yakni *pre-processing data*, *training*, validasi berkala, dan evaluasi akhir (OTI) serta generasi untuk HTI.

3.2.1. Persiapan *Environment* dan Data

- ***Environment***: Google Colab dengan GPU. *Library* utama: *diffusers*, *torchmetrics*, *torchvision*, *OpenCV*, dan *matplotlib*
- ***Struktur data***: Dataset berbentuk triplet (*erased*, *orig*, *mask*) yang dirujuk melalui *index.csv* di tiap *split* (*train*, OTI, HTI).
- ***Pre-processing***:
 - Gambar RGB di-*resize* ke 256x256 dan dinormalisasi ke rentang $[-1, 1]$ ($mean=0.5$, $std=0.5$).
 - Mask *grayscale* di-*resize* dengan interpolasi *nearest* lalu dibinarisasi (nilai 1 = area hilang)
- ***DataLoader***:
 - *Train*: triplets_out (~3440 sampel), *shuffle* aktif.
 - Validasi OTI: triplets_val_OTI (20) sampel, tanpa *shuffle*.
 - HTI: hanya *erased* + *mask* (tanpa *orig/GT*), dipakai untuk generasi dan pengukuran waktu inferensi.

3.2.2. Arsitektur Model dan Scheduler

- ***Model***: UNet2DModel (*diffusers*) dengan *attention* di beberapa blok, diaktifkan *gradient checkpointing* untuk efisiensi memori.
- ***Scheduler***:
 - *Training*: DDPM Scheduler ($num_train_timesteps=1000$, *beta linear*)
 - Inferensi *Inpainting*: RePaintScheduler (konfigurasi serupa) yang mendukung strategi *resampling* khas RePaint.
- Optimasi AdamW ($lr=1e-4$), *cosine schedule* dengan *warmup* 500 langkah, *gradient accumulation* (4 langkah) untuk *batch* efektif lebih besar.

3.2.3. Training Loop

- Tujuan Pelatihan: model mempelajari *denoising* (memperkirakan *noise*) pada proses difusi, menggunakan *loss* MSE antara prediksi *noise* dan *noise* acak yang ditambahkan.
- Prosedur:
 - Ambil *batch* gambar asli (*orig*) sebagai *clean_images*.

- Tambahkan *noise* sesuai *timesteps* (0-999) menggunakan DDPMScheduler → *noisy_images*.
- UNet memprediksi *noise*; hitung *loss* MSE.
- Lakukan *backward* dengan *mixed precision* (amp), langkah optimisasi mengikuti akumulasi gradien.
- **Monitoring:**
 - Cetak *loss* rata-rata per *epoch* dan waktu berlalu.
 - Setiap 10 *epoch*: simpan *checkpoint* RePaintPipeline dan buat *spanshop* visual (*grid* tiga baris: *input* citra yang ingin diperbaiki, prediksi *inpainted*, *ground truth*).

3.2.4. Evaluasi OTI (dengan **Ground Truth**)

- **Pipeline:** RePaintPipeline.from_pretrained(checkpoint) + RePaintScheduler.
- **Inferensi per sampel:**
 - *Input*: erased + mask; parameter contoh: num_inference_steps=50, jump_length=10, jump_n_sample=10, eta=0.0.
 - Keluaran: citra hasil *inpainting*.
- **Metrik:**
 - PSNR dan SSIM (rekonstruksi piksel).
 - LPIPS (persepsi/kemiripan fitur).
- **Output:**
 - Simpan per-gambar hasil rekonstruksi.
 - Buat *grid* komposit (*input* | prediksi | *ground truth*).
 - Tulis CSV berisi *filename*, PSNR, SSIM, LPIPS, dan waktu inferensi; tampilkan ringkasan *mean* serta kasus terbaik/terburuk.

3.2.5. Generasi HTI (tanpa **Ground Truth**)

Skenario HTI dirancang khusus untuk simulasi demonstrasi *on-the-spot*. Pada tahap ini, tidak ada proses pelatihan ulang (*re-training*). Inferensi dilakukan sepenuhnya menggunakan model yang telah dilatih dan divalidasi pada tahap OTI sebelumnya.

Untuk skenario HTI, kami merancang alur yang cepat, jelas, dan bisa diulang. Begitu model siap, kami hanya bermodalkan dua hal, gambar yang telah “dihapus” sebagian (*erased*) dan *mask* biner yang menunjukkan area kosong tanpa adanya *ground truth*. *Pipeline* RePaint kemudian kami jalankan pada pasangan *erased* dan *mask* tersebut. Hasilnya lahir dari

proses difusi yang bolak-balik menyelaraskan batas yang masih utuh dengan bagian yang harus dipulihkan.

Setiap keluaran kami simpan dengan penamaan yang rapi, *suffix* “_erased” pada nama berkas dihapus agar sesuai format *submission*. Di balik layar, *stopwatch* kami nyalakan sejak inferensi dimulai hingga selesai untuk setiap gambar. Waktu inferensi itu kami kumpulkan ke dalam satu berkas “inference_times.csv” agar mudah dianalisis, seberapa cepat model merespons, seberapa stabil performanya dari satu contoh ke contoh lain.

Kami menyusun sebuah *overview grid*, di sebelah kiri tampil *input* yang sudah “berlubang”, di sebelah kanan tampil prediksi hasil *inpainting* supaya hasilnya bisa dilihat sekilas tanpa membuka satu per satu. Terakhir, seluruh rekonstruksi kami kemas ke dalam satu arsip “CVitamin_HTI.zip”

3.2.6. Variabel Kunci untuk Analisis

Dalam analisis kami, ada beberapa variabel kunci yang menentukan bagaimana kualitas hasil inpainting berhadapan dengan efisiensi waktu. Pertama, strategi *resampling* RePaint melalui konfigurasi *num_inference_steps*, *jump_length*, dan *jump_n_sample* yang secara nyata mempengaruhi seberapa mulus pertemuan antara piksel yang masih utuh dengan area yang diisi. Lebih banyak langkah biasanya memberi kesempatan model untuk menyelaraskan tepi dan tekstur secara lebih halus, tetapi konsekuensinya waktu inferensi bertambah. karena itu, eksperimen kami sengaja menyeimbangkan kualitas tepi dengan kebutuhan demo yang responsif.

Kedua, karakteristik data emoji sendiri membawa tantangan khusus. Warna-warna solid (*flat colors*) dan tepi yang tegas (*sharp edges*) menuntut ketelitian tinggi pada batas objek. Di sini, SSIM dan LPIPS menjadi metrik yang bukan sekadar angka, keduanya membantu kami menangkap kualitas perseptual dan konsistensi struktur, sementara inspeksi visual terhadap “*border sharpness*” memastikan hasil tidak tampak kabur atau pecah di area transisi.

Ketiga, kami memisahkan peran OTI dan HTI untuk membaca kemampuan generalisasi dari dua sisi, OTI memberikan gambaran akurasi rekonstruksi karena tersedia *ground truth*, sedangkan HTI menguji ketahanan operasional di kondisi nyata tanpa acuan, sekaligus mengamati kecepatan model pada berbagai contoh. Dengan pendekatan ini, desain

eksperimen tidak hanya memotret performa model dalam angka, tetapi juga menilai pengalaman pengguna yang kami kejar, hasil yang tajam, waktu yang wajar, dan perilaku yang stabil saat dipamerkan secara *on-the-spot*.

4. Hasil dan Analisis

4.1. Hasil Eksperimen

Analisis progresi pelatihan dilakukan terlebih dahulu untuk mengamati peningkatan kualitas model dari waktu ke waktu. Gambar 1 memperlihatkan perbandingan hasil rekonstruksi antara *checkpoint* menengah (Epoch 50) dan model final (Epoch 100).



Gambar 1. Perbandingan Kualitas Rekonstruksi pada Epoch 50 dan Epoch 100

Setelah model mencapai konvergensi pada Epoch 100, evaluasi dilakukan pada dataset *Open Test Images* (OTI). Berikut adalah visualisasi semua hasil rekonstruksi dari *inpainting* yang telah dilakukan. Gambar 2 memperlihatkan perbandingan antara citra masukan yang rusak (*masked*), hasil rekonstruksi model RePaint, dan citra asli (*ground truth*).

OTI results (Left: Input | Center: Prediction | Right: Ground Truth)



Gambar 1. Hasil Visualisasi Rekonstruksi Citra pada Dataset OTI

Secara visual, model mampu mengisi area yang hilang dengan warna dan tekstur yang menyatu dengan area sekitarnya. Batas antara piksel asli dan piksel hasil inpainting terlihat harmonis tanpa adanya jahitan (*seam*) yang kasar.

Tabel 1. Hasil Evaluasi Kuantitatif pada Dataset OTI

Metrik Evaluasi	Nilai Rata-rata
PSNR (<i>Peak Signal-to-Noise Ratio</i>)	10,44 dB
SSIM (<i>Structural Similarity Index</i>)	0,701
LPIPS (<i>Learned Perceptual Image Patch Similarity</i>)	0,319

Berdasarkan Tabel 1, model menghasilkan rata-rata SSIM sebesar 0,701 dan PSNR 10,44 dB. Nilai ini menunjukkan bahwa rekonstruksi citra memiliki tingkat kemiripan struktur yang moderat, tetapi akurasi piksel warnanya masih memiliki selisih yang cukup signifikan dibandingkan *ground truth*.

Selanjutnya, dilakukan pengukuran efisiensi waktu inferensi untuk menjawab pertanyaan penelitian terkait kelayakan penggunaan model secara *real-time*.

Tabel 2. Hasil Percobaan Kecepatan Inferensi

Parameter	Hasil Pengukuran
Jumlah Langkah Difusi (<i>Steps</i>)	100
Rata-rata Waktu Inferensi per Citra	~12,65 detik

Pengukuran waktu inferensi pada dataset uji menunjukkan hasil yang sangat konsisten, berkisar antara 12,42 hingga 12,80 detik per citra, dengan rata-rata 12,65 detik.

4.2. Diskusi

Pada tahap awal, model cenderung hanya mempelajari distribusi warna rata-rata yang menjelaskan mengapa hasil pada Epoch 50 terlihat *blurry*. Penambahan durasi hingga 100 *epoch* terbukti esensial bagi model difusi untuk melakukan *refinement* tekstur dan mengharmonisasikan batas antara area *masked* dan *unmasked* sehingga menjawab pertanyaan penelitian terkait pentingnya proses iteratif dalam mencapai kualitas visual yang optimal.

Nilai PSNR yang relatif rendah (10,44 dB) mengindikasikan adanya tantangan besar bagi model dalam mereplikasi warna solid yang presisi pada emoji. Berbeda dengan citra alamiah (*natural images*) yang memiliki variasi tekstur tinggi, emoji memiliki area warna datar (*flat regions*) yang luas. Kesalahan kecil pada warna di area datar akan dihukum berat oleh metrik PSNR. Meskipun

demikian, nilai SSIM 0,701 menunjukkan bahwa struktur global (bentuk lingkaran wajah, posisi mata) masih dapat dipertahankan dengan cukup baik.



Gambar 2. Perbandingan Visual antara Kasus Terbaik (Kiri) dan Kasus Terburuk (Kanan)

Analisis mendalam dilakukan terhadap sampel yang memiliki kinerja ekstrim untuk memahami karakteristik kegagalan model. Berdasarkan Gambar 2 (kiri), sampel 6__val_m03 tercatat sebagai kasus terbaik dengan skor LPIPS 0.156 dan PSNR 10.85 dB. Hal ini menunjukkan bahwa model sangat efektif menangani jenis kerusakan pada sampel m03. Kemungkinan besar, *mask* pada sampel ini tidak menutupi fitur semantik vital atau memiliki area yang relatif kecil sehingga model dapat memulihkan struktur dan warna dengan presisi tinggi yang disukai oleh metrik piksel (PSNR) maupun persepsi (LPIPS).

Sebaliknya, pada kasus terburuk (72__val_m04 di kanan), secara konsisten muncul sebagai sampel dengan kinerja terburuk pada metrik SSIM (0.577) dan LPIPS (0.576). Rendahnya nilai SSIM (<0.6) pada kasus ini mengindikasikan kegagalan struktural yang parah. Kegagalan struktur ini berbanding lurus dengan tingginya nilai LPIPS, yang berarti hasil rekonstruksi terlihat tidak alami atau "aneh" secara perseptual. Fenomena ini, yang sering disebut sebagai "halusinasi semantik", terjadi karena hilangnya petunjuk kontekstual (*contextual cues*) yang diperlukan model untuk memprediksi ekspresi wajah yang spesifik.

Waktu inferensi rata-rata $\sim 12,6$ detik per citra menunjukkan bahwa metode ini berat secara komputasi. Hal ini menegaskan bahwa penggunaan RePaint lebih cocok untuk restorasi *offline* berkualitas tinggi daripada aplikasi *real-time*. Durasi tersebut masih berada dalam batas wajar untuk skenario demonstrasi *on-the-spot* yang melibatkan pemrosesan gambar tunggal atau *batch* kecil (*Hidden Test Images*).

5. Penutup

5.1. Kesimpulan

Penelitian ini menyimpulkan bahwa metode RePaint berbasis *Denoising Diffusion Probabilistic Models* (DDPM) mampu melakukan restorasi citra emoji dengan kualitas perseptual yang cukup baik pada kerusakan tingkat ringan hingga menengah. Model terbukti efektif dalam mengharmonisasikan tekstur dan warna tanpa meninggalkan artefak batas yang kasar, terutama setelah melalui proses pelatihan yang memadai hingga 100 *epoch*. Namun, ketahanan model masih terbatas pada ketersediaan konteks global, yaitu kerusakan masif yang menghilangkan fitur semantik utama cenderung menyebabkan model menghasilkan prediksi yang menyimpang dari ekspresi asli *ground truth* meskipun secara visual terlihat alami. Selain itu, tingginya waktu inferensi menjadikan metode ini lebih sesuai untuk restorasi *offline* berkualitas tinggi dibandingkan implementasi *real-time*.

5.2. Saran (*Future Work*)

Saran dari tim peneliti untuk penelitian yang relevan kedepannya sebagai berikut.

1. Melakukan eksperimen lebih lanjut terkait *hyperparameter tuning*, khususnya pada parameter vital, seperti *learning rate*, *batch size*, serta konfigurasi *noise schedule* pada model difusi. Penyesuaian parameter ini bertujuan untuk mencari keseimbangan optimal antara kecepatan konvergensi saat pelatihan dan kualitas detail gambar yang dihasilkan.
2. Menambah jumlah dan variasi data pelatihan dengan memasukkan berbagai jenis emoji lain di luar dataset yang telah diberikan saat ini. Dengan memperkaya dataset menggunakan gaya desain, bentuk, dan palet warna emoji yang lebih beragam, diharapkan model dapat mempelajari distribusi fitur yang lebih general. Hal ini penting untuk meningkatkan *robustness* model agar tidak hanya jago pada emoji tipe tertentu saja, tetapi juga mampu menangani pola struktur yang lebih kompleks.

5.3. Refleksi Kelompok

Proyek *Image Inpainting* menggunakan RePaint ini memberikan tantangan teknis bagi tim CVitamin. Kendala utama yang dihadapi adalah tingginya kebutuhan komputasi (*computational cost*) dari model difusi yang membuat proses eksperimen dan evaluasi memakan waktu cukup lama. Selain itu, kami menyadari bahwa mengevaluasi kualitas gambar hasil generasi tidak cukup hanya dengan angka (PSNR/SSIM), melainkan memerlukan inspeksi visual yang teliti untuk memahami konteks kegagalan semantik model.

Daftar Referensi

- [1]. M. Bertalmio, G. Sapiro, V. Caselles, and C. Ballester, "Image inpainting," in *Proc. 27th Annu. Conf. Comput. Graph. Interactive Tech.*, 2000, <https://dl.acm.org/doi/10.1145/344779.344972>
- [2]. C. Barnes, E. Shechtman, A. Finkelstein, and D. B. Goldman, "PatchMatch: A randomized correspondence algorithm for structural image editing," *ACM Trans. Graph.*, vol. 28, no. 3, Art. no. 24, Aug. 2009. <https://dl.acm.org/doi/10.1145/1531326.1531330>
- [3]. D. Pathak, P. Krähenbühl, J. Donahue, T. Darrell, and A. A. Efros, "Context encoders: Feature learning by inpainting," arXiv. 2016. <https://arxiv.org/abs/1604.07379>
- [4]. J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," arXiv. 2020. <https://arxiv.org/abs/2006.11239>
- [5]. A. Lugmayr, M. Danelljan, A. Romero, F. Yu, R. Timofte, and L. Van Gool, "RePaint: Inpainting using denoising diffusion probabilistic models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022. <https://arxiv.org/abs/2201.09865>
- [6]. A. Horé and D. Ziou, "Image quality metrics: PSNR vs. SSIM," in *2010 20th Int. Conf. Pattern Recognit.*, 2010. https://www.researchgate.net/publication/220931731_Image_quality_metrics_PSNR_vs_SSIM
- [7]. R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018. <https://arxiv.org/abs/1801.03924>